Synthèse

Ce rapport compare six modèles d'embeddings et quatre modèles de génération exécutés en local avec Ollama, sur un PC sans GPU. Côté recherche, `nomic-embed-text` obtient le meilleur Top-1 (94 %) et le meilleur MRR (0,959) pour le plus petit poids après `all-minilm`. Côté génération, `qwen2.5:3b` obtient le meilleur score global (97 %) et n'a jamais inventé de réponse. Nous retenons donc le couple `qwen2.5:3b` + `nomic-embed-text`, avec une architecture où le calcul des propositions de parfums reste dans le code et non dans le LLM.

1 Contexte du projet

Notre projet de hackathon est un chatbot « Trouver mon parfum ». L'utilisateur clique sur un bouton, règle des curseurs (plus chaleureux, plus frais, etc.), et l'application affiche des propositions de parfums sur trois colonnes.

Notre première version technique est un assistant RAG composé de :

— une base vectorielle **ChromaDB** ;

— une API **FastAPI** ;

— des modèles **Ollama** exécutés en local.

La base contient un dossier de 14 chapitres sur Givaudan (histoire, résultats 2024 à 2026, stratégie 2030, durabilité), découpé en 35 morceaux d'environ 800 caractères.

2 Protocole

— **Matériel :** PC Microsoft Surface, AMD Ryzen 5, 7,5 Go de RAM, sans GPU. Ollama 0.40.16.

— **Questions :** 36 questions en français, dont 32 avec réponse dans le dossier et 4 pièges sans réponse (salaire du CEO, cours de bourse du jour, nombre de brevets en 2025, chiffre d'affaires 2027).

— **Notation automatique :** une réponse est juste si le chiffre ou le nom attendu y figure. Un piège est réussi si le modèle dit que l'information manque, au lieu d'inventer.

— **Conditions identiques :** même prompt système pour tous les modèles, température 0, contexte de 4096 tokens. Les mêmes 4 passages, retrouvés avec `nomic-embed-text`, sont envoyés à chaque modèle.

3 Résultats des modèles d'embeddings

Le Top-1 indique la part des questions pour lesquelles le bon chapitre arrive en première position ; le Top-4, la part pour laquelle il figure dans les quatre premiers résultats. Le MRR (*Mean Reciprocal Rank*) résume le rang moyen du bon chapitre (1 = toujours premier).

Tableau 1. Comparaison des modèles d'embeddings.

Modèle	Taille	Top-1	Top-4	MRR	Indexation	Requête
`nomic-embed-text`	0,27 Go	94 %	97 %	0,959	15,9 s	73 ms
`embeddinggemma`	0,62 Go	91 %	100 %	0,953	17,9 s	64 ms
`bge-m3`	1,16 Go	91 %	100 %	0,945	38,4 s	126 ms
`qwen3-embedding:0.6b`	0,64 Go	84 %	88 %	0,869	54,1 s	271 ms
`mxbai-embed-large`	0,67 Go	66 %	94 %	0,796	37,3 s	173 ms
`all-minilm`	0,05 Go	62 %	75 %	0,720	2,7 s	18 ms

Note : les temps d'indexation de `bge-m3`, `qwen3-embedding`, `embeddinggemma` et `all-minilm` ont été mesurés pendant qu'un autre test tournait sur la machine. Ils sont légèrement surestimés.

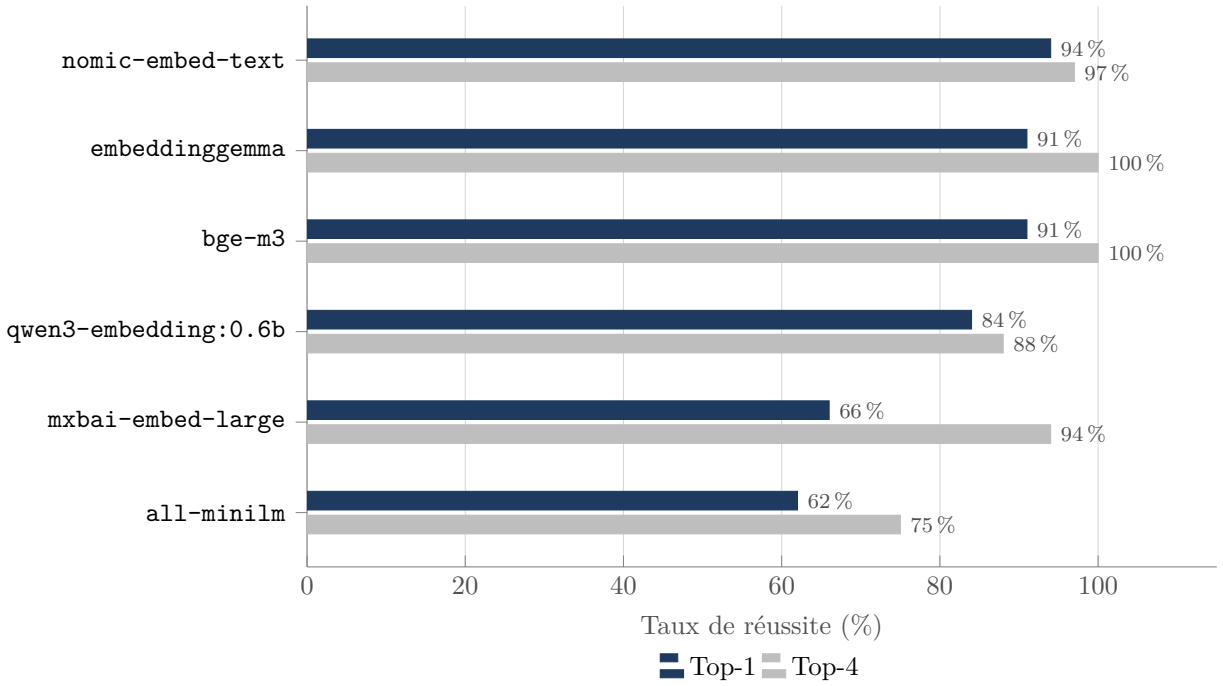


Figure 1. Précision de la recherche par modèle d'embeddings (Top-1 et Top-4).

`nomic-embed-text` est le meilleur en Top-1 et en MRR, tout en restant léger (0,27 Go) et rapide à indexer. `embeddinggemma` et `bge-m3` atteignent 100 % en Top-4 mais placent moins souvent le bon chapitre en tête. `all-minilm` est de loin le plus rapide, mais sa précision est trop faible pour notre usage.

4 Résultats des modèles de génération

Le score global correspond à la part des 36 questions réussies (réponses justes et pièges refusés). Le temps médian est mesuré par réponse, et la vitesse en tokens générés par seconde.

Tableau 2. Comparaison des modèles de génération.

Modèle	Disque	RAM	Justesse (/32)	Pièges refusés (/4)	Score global	Temps médian	Vitesse
`qwen2.5:3b`	1,93 Go	2,17 Go	97 % (31)	100 % (4)	**97 %**	20,7 s	12,4 tok/s
`gemma3:1b`	0,81 Go	0,88 Go	94 % (30)	100 % (4)	94 %	16,2 s	19,7 tok/s
`llama3.2:3b`	2,02 Go	2,57 Go	94 % (30)	100 % (4)	94 %	27,4 s	8,6 tok/s
`qwen2.5:1.5b`	0,99 Go	1,17 Go	97 % (31)	50 % (2)	92 %	6,8 s	21,6 tok/s

Modèles écartés ou non testés.

- `qwen3:4b` a été testé sur 3 questions seulement : réponses justes, mais 99 à 169 s par réponse (son mode « réflexion » restait actif). Il a été écarté comme trop lent.
- Les modèles de 7 à 8 milliards de paramètres (`mistral:7b`, `qwen2.5:7b`, `llama3.1:8b`) n'ont pas été testés : RAM insuffisante et réseau trop lent pour les télécharger.

5 Analyse

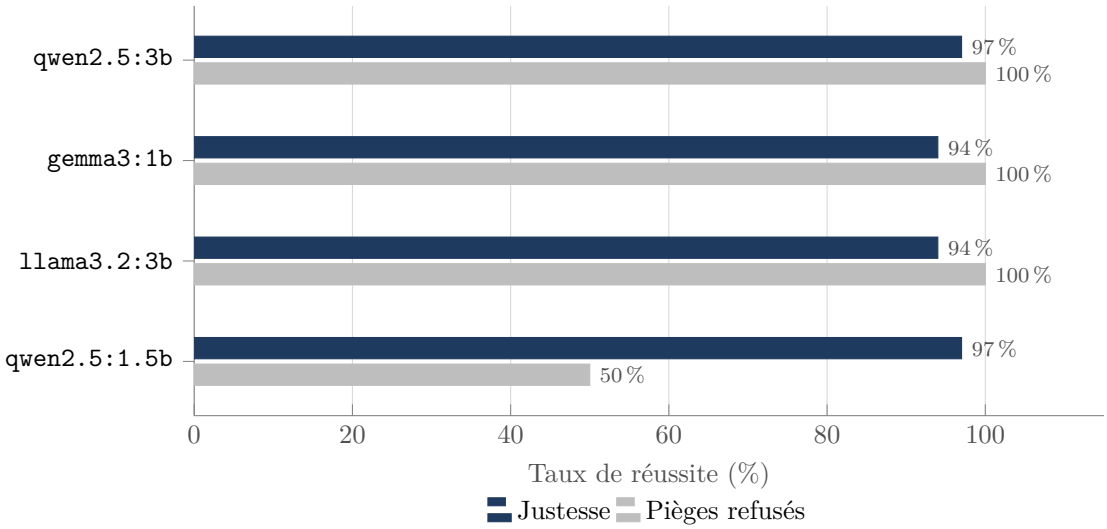


Figure 2. Justesse sur les 32 questions avec réponse et refus des 4 pièges.

5.1 Analyse par modèle

`qwen2.5:3b` — le plus fiable
Il n'a jamais inventé. Sur la seule question ratée, il a répondu « Le dossier ne le précise pas ».

`qwen2.5:1.5b` — le plus rapide, mais il invente
Exemples : « Le cours de l'action Givaudan aujourd'hui est de 15 CHF par action », un chiffre d'affaires 2027 de « 6 478 millions de CHF », une croissance de « 12,3 % » au 3e trimestre 2026.

`gemma3:1b` — honnête sur les pièges et très léger
Il ne pèse que 0,9 Go, mais il a commis deux erreurs : il a confondu une région (Asie-Pacifique au lieu de SAMEA) et inventé une croissance de 6,8 % au 3e trimestre 2026.

`llama3.2:3b` — prudent, parfois trop
Il n'invente pas, mais il refuse parfois à tort : il a dit que la date du rachat par Roche n'était pas dans les extraits alors qu'elle y était. C'est le plus lent et le plus gourmand en RAM.

5.2 Point faible de la recherche

La question « croissance like-for-like au troisième trimestre 2026 » (réponse attendue : 8,6 %) a été ratée par tous les modèles, parce que `nomic-embed-text` n'a pas remonté le passage « Ventes des neuf premiers mois de 2026 ». `qwen2.5:3b` et `llama3.2:3b` ont dit qu'ils ne savaient pas ; `qwen2.5:1.5b` et `gemma3:1b` ont inventé.

Pistes de correction :

— envoyer 6 passages au lieu de 4 ;

— ajouter des mots-clés dans les fiches ;

— combiner recherche vectorielle et recherche par mots-clés.

6 Recommandation

Recommandation de l'équipe GR12_HEXA

— **Modèle de génération : `qwen2.5:3b`.** C'est le meilleur compromis entre justesse et honnêteté. Pour un produit qui conseille des parfums, mieux vaut un modèle qui dit « je ne sais pas » qu'un modèle rapide qui invente.

— **Embeddings : `nomic-embed-text`,** avec `bge-m3` en alternative si le catalogue de parfums est multilingue.

— **Architecture : les curseurs ne passent pas par le LLM.** Chaque parfum reçoit une note sur chaque axe, et le code calcule les 3 propositions les plus proches. Le LLM ne sert qu'à transformer une demande libre en valeurs de curseurs (JSON) et à rédiger une courte explication par proposition, en choisissant uniquement parmi les parfums fournis par le code.

— **Démo :** `qwen2.5:3b` met environ 20 s par réponse sur CPU. Il faut générer les 3 explications en un seul appel, afficher la réponse au fur et à mesure (streaming), ou utiliser une machine avec GPU.

7 Limites

— 36 questions seulement.

— Notation par mots-clés.

— Un seul PC, sans GPU.

— Le temps de `qwen2.5:1.5b` est peut-être un peu surestimé (un autre test tournait en même temps).

— Modèles de 7 milliards de paramètres et plus non testés.

— Questions factuelles seulement : il faudra tester la conversion en curseurs JSON et la qualité des explications.

A Résultats par question

✓ = réponse juste (ou piège refusé) ; ✗ = réponse fausse, refus à tort ou réponse inventée. Les questions 33 à 36 sont les pièges.

Tableau 3. Résultat de chaque modèle par question.

N°	Question	`qwen2.5:3b`	`gemma3:1b`	`llama3.2:3b`	`qwen2.5:1.5b`
1	CA 2025	✓	✓	✓	✓
2	Croissance like-for-like 2025	✓	✓	✓	✓
3	Dividende 2025	✓	✓	✓	✓
4	CEO depuis mars 2026	✓	✓	✓	✓
5	Année de fondation	✓	✓	✓	✓
6	Croissance de la parfumerie fine 2025	✓	✓	✓	✓
7	Bénéfice net du 1er semestre 2026	✓	✓	✓	✓
8	Année du net zéro	✓	✓	✓	✓
9	Principaux concurrents	✓	✓	✓	✓
10	CA des 9 premiers mois de 2026	✓	✓	✓	✓
11	Dette nette/EBITDA fin 2025	✓	✓	✓	✓
12	EBITDA 2025	✓	✓	✓	✓
13	Free cash flow 2025	✓	✓	✓	✓
14	CA Fragrance & Beauty 2025	✓	✓	✓	✓
15	CA Taste & Wellbeing 2025	✓	✓	✓	✓
16	Région la plus dynamique de Taste & Wellbeing 2025	✓	✗	✓	✓
17	Rachat par Roche	✓	✓	✗	✓
18	Séparation de Roche et entrée en bourse	✓	✓	✓	✓
19	Société rachetée en 2007	✓	✓	✓	✓
20	Ville du siège	✓	✓	✓	✓
21	Employés fin 2025	✓	✓	✓	✓
22	Croissance du 3e trimestre 2026	✗	✗	✗	✗
23	Électricité 100 % renouvelable depuis	✓	✓	✓	✓
24	Pourcentage de femmes à la direction	✓	✓	✓	✓
25	Objectif de croissance de la stratégie 2030	✓	✓	✓	✓
26	Croissance moyenne 2021–2025	✓	✓	✓	✓
27	CA 2024	✓	✓	✓	✓
28	Rachat de Naturex	✓	✓	✓	✓
29	Dette nette au 30 juin 2026	✓	✓	✓	✓
30	Marge EBITDA ajustée du 1er semestre 2026	✓	✓	✓	✓
31	CA Asie-Pacifique du 1er semestre 2026	✓	✓	✓	✓
32	Réduction des émissions scopes 1+2	✓	✓	✓	✓
33	Salaire du CEO *(piège)*	✓	✓	✓	✓
34	Cours de l'action *(piège)*	✓	✓	✓	✗
35	Brevets 2025 *(piège)*	✓	✓	✓	✓
36	CA 2027 *(piège)*	✓	✓	✓	✗
	Total réussi (/36)	**35**	**34**	**34**	**33**